RMUTP

การวิเคราะห์ความคิดเห็นของผู้ใช้บริการแอปพลิเคชัน Lazada จาก Google Play Store

SENTIMENT ANALYSIS OF USER REVIEWS FOR THE LAZADA APPLICATION ON GOOGLE PLAY STORE

RMUTP

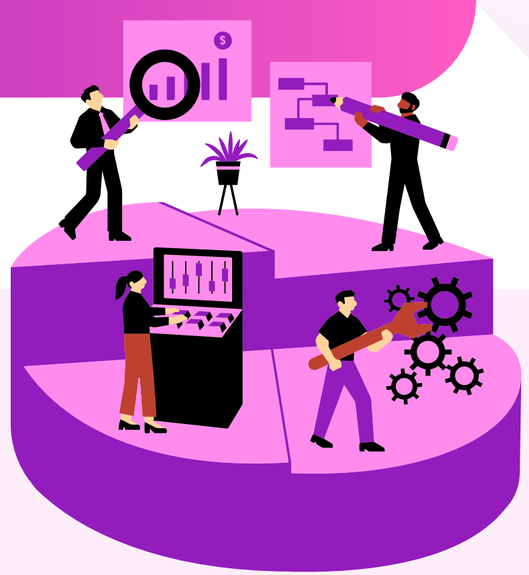

ความเป็นมาและความสำคัญ

ในยุคดิจิทัลที่การซื้อสินค้าออนไลน์กลายเป็นเรื่องปกติ ตลาดอีคอมเมิร์ซเติบโตอย่างรวดเร็ว โดยเฉพาะในเอเชียตะวันออกเฉียงใต้ที่มีผู้ใช้อินเทอร์เน็ตจำนวนมาก แพลตฟอร์มต่าง ๆ จึงต้องแข่งขันกันทั้งด้านระบบ ความรวดเร็ว และประสบการณ์ผู้ใช้

Lazada เป็นหนึ่งในแพลตฟอร์มอีคอมเมิร์ซขนาดใหญ่ที่ได้รับความนิยม ด้วยระบบ Marketplace ที่ครบวงจรและการให้บริการที่ครอบคลุม อย่างไรก็ตาม เมื่อการแข่งขันสูงขึ้น ความคาดหวังของผู้ใช้งานก็เพิ่มขึ้นตาม ส่งผลให้รีวิวผู้ใช้บน Google Play Store กลายเป็นแหล่งข้อมูลสำคัญที่สะท้อนทั้งปัญหาและความพึงพอใจจริง แต่รีวิวเหล่านี้เป็นข้อมูลข้อความจำนวนมากและซับซ้อน จึงยากต่อการวิเคราะห์ด้วยวิธีทั่วไป

ดังนั้น งานวิจัยนี้จึงนำเทคนิค NLP และ Machine Learning มาใช้ในการวิเคราะห์รีวิว เพื่อเข้าใจความคิดเห็นและความรู้สึกของผู้ใช้อย่างเป็นระบบ และนำไปสู่การพัฒนาบริการได้อย่างตรงจุด

RMUTP

วัตถุประสงค์ของโครงงาน

- เพื่อพัฒนาโมเดลการวิเคราะห์ความคิดเห็น (Sentiment Analysis) ของรีวิวแอปพลิเคชัน Lazada โดยใช้โมเดล WangchanBERTa สำหรับจำแนกรีวิวเป็นเชิงบวก (Positive) เชิงลบ (Negative) และเป็นกลาง (Neutral)
- เพื่อวิเคราะห์ประสิทธิภาพของโมเดลในการจำแนกประเด็นความคิดเห็น (Aspect Classification)
- เพื่อวิเคราะห์และจัดหมวดหมู่ประเด็น (Aspect-Based Analysis) ของข้อความรีวิวออกเป็น 5 ด้าน ได้แก่ ระบบของเว็บไซต์และแอปพลิเคชั่น (System), ระบบขนส่ง (Logistics), บริษัท (Company), ร้านค้าภายในแพลตฟอร์ม (Store), โปรโมชั่นในแพลตฟอร์ม (Promotion)
- เพื่อสรุปข้อมูลความคิดเห็นของผู้ใช้งาน โดยแสดงสัดส่วนความคิดเห็นเชิงบวก เชิงลบ และเป็นกลางในระดับภาพรวม และแสดงจำนวนความคิดเห็นจำแนกตามแต่ละประเด็น เพื่อสะท้อนจุดเด่นและจุดด้อยของแอปพลิเคชันในมุมมองของผู้ใช้งาน ผ่านการนำเสนอในรูปแบบ Visualization
- เพื่อพัฒนา Dashboard ด้วย Power BI สำหรับนำเสนอผลการวิเคราะห์ในลักษณะต้นแบบ เพื่อใช้เป็นแบบอย่างสำหรับการนำไปพัฒนาและสนับสนุนการตัดสินใจเชิงธุรกิจในอนาคต

RMUTP

ขอบเขตของโครงงาน

ขอบเขตด้านข้อมูล

โดยงานวิจัยนี้ใช้ข้อมูลรีวิวจาก Google Play Store จำนวน 30,000 รายการ ซึ่งดึงข้อมูลด้วยไลบรารี google play scraper ครอบคลุมช่วงปี ค.ศ. 2023 ถึง 2025

ขอบเขตด้านภาษา

โดยใช้เฉพาะข้อความรีวิวภาษาไทยเท่านั้น เพราะเหมาะสำหรับการประมวลผลด้วยเทคนิค Natural Language Processing

ขอบเขตด้านเทคนิคและเครื่องมือ

- ใช้โมเดล WangchanBERTa สำหรับการวิเคราะห์อารมณ์ความรู้สึก
- พัฒนาโค้ดด้วยภาษา Python บน Google Colaboratory ร่วมกับไลบรารี Thai NLP
- ใช้โมเดล Random Forest และ Naïve Bayes สำหรับ Aspect Classification
- พัฒนา Dashboard บน Power BI เพื่อแสดงผลการวิเคราะห์

ขอบเขตด้านการวิเคราะห์

- วิเคราะห์ความคิดเห็นโดยแยกเป็น 3 ประเภท คือ เชิงบวก, เชิงลบ, และ เป็นกลาง
- จำแนกประเด็น (Aspect Classification) ของรีวิวผู้ใช้แอปพลิเคชัน Lazada ออกเป็น 5 หมวด ได้แก่ ระบบของเว็บไซต์และแอปพลิเคชั่น (System) ระบบขนส่ง (Logistics) บริษัท (Company) ร้านค้าภายในแพลตฟอร์ม (Store) โปรโมชั่นในแพลตฟอร์ม (Promotion)
- สรุปภาพรวมความคิดเห็นของผู้ใช้งานในด้านบวก ลบ และเป็นกลางในรูปแบบร้อยละ และวิเคราะห์ความคิดเห็นในแต่ละประเด็นในรูปแบบจำนวนความคิดเห็น เพื่อสะท้อนคุณภาพการให้บริการของแพลตฟอร์ม และชี้จุดที่ควรปรับปรุงหรือพัฒนาต่อไป
- พัฒนา Dashboard ด้วย Power BI เพื่อแสดงผลลัพธ์ของ Sentiment และ Aspect Classification ผ่านรูปแบบ Visualization

RMUTP

ขั้นตอนการดำเนินงาน

ขั้นตอนที่ 1 การเก็บรวบรวมข้อมูล

- ดึงข้อมูลรีวิวจาก Google Play Store โดยใช้ไลบรารี google-play-scraper ที่เรียกข้อมูลผ่าน API
- ดึงเฉพาะรีวิวภาษาไทยจากผู้ใช้ในประเทศไทย
- เก็บข้อมูล ข้อความรีวิว, วันที่, คะแนน และข้อมูลประกอบอื่นๆ ตามที่แพลตฟอร์มเผยแพร่

ขั้นตอนที่ 2 เตรียมและทำความสะอาดข้อมูล

- ลบอักขระพิเศษ/เว้นวรรคผิดปกติ
- ตัดคำด้วย PyThaiNLP
- แปลงข้อความเป็นเวกเตอร์ด้วย TF-IDF

ขั้นตอนที่ 3 การจำแนกประเด็น

- ใช้ Pattern Matching จับคำสำคัญ
- ใช้ Random Forest และ Naïve Bayes ร่วมกับ TF-IDF
- การจำแนกถูกแบ่งเป็น 5 หมวด: System, Logistics, Company, Store, Promotion

ขั้นตอนที่ 4 วิเคราะห์อารมณ์ความรู้สึก

- ใช้โมเดล WangchanBERTa
- จำแนกความคิดเห็นออกเป็น Positive / Negative / Neutral

ขั้นตอนที่ 5 สรุปผลการวิเคราะห์

- จำนวนและสัดส่วนรีวิวแต่ละประเภท
- หมวดประเด็นที่ถูกกล่าวถึงมากที่สุด
- เพื่อให้สามารถวิเคราะห์แนวโน้มและความต้องการของผู้ใช้งานได้อย่างละเอียด

ขั้นตอนที่ 6 สร้าง Dashboard (Power BI)

- แสดงผลลัพธ์ในรูปแบบกราฟ ตาราง และภาพสรุป
- ช่วยให้เห็นภาพรวมข้อมูลและอินไซต์อย่างชัดเจน

ขั้นตอนที่ 7 จัดทำรายงาน & สรุปผล

- เขียนรายงานรวมผลทั้งหมด
- อภิปรายผล ปัญหา ข้อจำกัด
- เสนอแนวทางสำหรับการนำไปพัฒนาและสนับสนุนการตัดสินใจเชิงธุรกิจในอนาคต

RMUTP

ขั้นตอนการดึงข้อมูล

```
กำลังดึงชุดที่ 0 - 2000 ...
กำลังดึงชุดที่ 2000 - 4000 ...
กำลังดึงชุดที่ 4000 - 6000 ...
กำลังดึงชุดที่ 6000 - 8000 ...
กำลังดึงชุดที่ 8000 - 10000 ...
กำลังดึงชุดที่ 10000 - 12000 ...
กำลังดึงชุดที่ 12000 - 14000 ...
กำลังดึงชุดที่ 14000 - 16000 ...
กำลังดึงชุดที่ 16000 - 18000 ...
กำลังดึงชุดที่ 18000 - 20000 ...
กำลังดึงชุดที่ 20000 - 22000 ...
กำลังดึงชุดที่ 22000 - 24000 ...
กำลังดึงชุดที่ 24000 - 26000 ...
กำลังดึงชุดที่ 26000 - 28000 ...
กำลังดึงชุดที่ 28000 - 30000 ...
ดึงมาได้ทั้งหมด: 30000
บันทึกไฟล์เสร็จแล้ว!
```

ทำการดึงข้อมูลรีวิวจากแอปพลิเคชัน Lazada บน Google Play Store กำหนดจำนวนรีวิวที่จะดึงทั้งหมด 30,000 รีวิวและดึงข้อมูลเป็นรอบ ๆ เพื่อป้องกันการถูกจำกัดการเข้าถึง จากนั้นนำข้อมูลที่ได้มาจัดเก็บในรูปแบบไฟล์ Excel และ CSV เพื่อใช้เป็นข้อมูลตั้งต้นสำหรับการวิเคราะห์ในขั้นตอนถัดไป

ส่วนที่ 1 กระบวนการทำความสะอาดและเตรียมข้อมูลรีวิวภาษาไทย

```
1) โหลดไฟล์: lazada30.csv
   จำนวนแถวทั้งหมด (raw): 30000
   คอลัมน์ทั้งหมด: ['reviewId', 'userName', 'userImage', 'content', 'score', 'thumbsUpCount', 'reviewCreatedVersion', 'at', 'replyContent', 'repliedAt', 'appVersion']

   ตัวอย่าง 5 แถวแรก (raw):
```

	reviewId	userName	userImage	content	score	thumbsUpCount	reviewCreatedVersion	at	replyContent	repliedAt	appVersion
0	cb2a5ad0-b0ee-442b-be21-8c8d09c2089b	[redacted]	https://play-lh.googleusercontent.com/a-/ALV-U...	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เน...	5	0	NaN	2025-11-30 16:01:52	[redacted] ดีใจที่คุณเริ่มใช้งานแอปได้คล่...	2025-11-30 16:10:26	NaN
1	3cea7a5d-0ce7-4d3e-ad34-a91c95b8adcc	[redacted]	https://play-lh.googleusercontent.com/a-/ALV-U...	ส่งของช้ากว่ากำหนดบ่อยมาก สั่ง5ชิ้น จะมี2-3ชิ้...	1	0	7.88.0	2025-11-30 14:07:11	[redacted], ขอบคุณที่แชร์ประสบการณ์ของค...	2025-11-30 14:15:31	7.88.0
2	da0ef0cf-e141-42aa-a9b7-4d17ccd27ea2	[redacted]	https://play-lh.googleusercontent.com/a-/ALV-U...	ซื้อของที่LaZaDaเวลาของเสียเคลมง่ายไม่ยุ่งยากคะ	5	0	7.88.0	2025-11-30 14:02:16	สวัสดีค่ะ [redacted] ขอบคุณมากสำหรับคะ...	2025-11-30 14:10:25	7.88.0
3	60e79c20-c630-4560-861e-301ff41c7a08	[redacted]	https://play-lh.googleusercontent.com/a/ACg8oc...	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	3	0	7.88.0	2025-11-30 13:03:14	ขอบคุณสำหรับความคิดเห็นที่มีค่าของคุณนะคะ คุณ ...	2025-11-30 13:10:30	7.88.0
4	c1a91431-36aa-477a-bd00-35094c90f7a1	[redacted]	https://play-lh.googleusercontent.com/a/ACg8oc...	ส่งข้อความมาให้สมัครแบบผ่อนชำระ แต่พอกดเข้าไปบ...	1	0	7.88.0	2025-11-30 09:07:27	สวัสดีค่ะ [redacted] ขอบคุณที่แชร์ความคิดเ...	2025-11-30 09:20:29	7.88.0

RMUTP

แยกจำนวนข้อมูลตามปี

```
1) จำนวนข้อมูลตามปี (จากคอลัมน์ 'at')
----------------------------------------------------
year
2023     2202
2024    20546
2025     7252
Name: count, dtype: int64
```

คัดเลือกคอลัมน์และบันทึกข้อมูล

```
2) ตรวจสอบข้อมูลซ้ำ
----------------------------------------------------
- จำนวน reviewId ซ้ำ: 0 ค่า   (จำนวนแถวที่ซ้ำทั้งหมด: 0)

3) ตรวจภาษาอังกฤษในคอลัมน์ 'content'
----------------------------------------------------
- จำนวนแถวที่มีภาษาอังกฤษใน content: 2470
```

```
4) ลบแถวที่มีภาษาอังกฤษ
----------------------------------------
- จำนวนแถวก่อนลบ: 30000
- จำนวนแถวหลังลบ: 27530
- ลบออกทั้งหมด: 2470 แถว
```

แยกจำนวนข้อมูลตามปี (หลังจากลบข้อมูลซ้ำและภาษาอังกฤษแล้ว)

```
1) จำนวนข้อมูลตามปี (จากคอลัมน์ 'at') — หลังลบข้อมูลแล้ว
----------------------------------------------------
ปี 2023: 2035 แถว
ปี 2024: 19050 แถว
ปี 2025: 6445 แถว

ลบข้อมูลปี 2023 ออก...

1.1) จำนวนข้อมูลตามปี — หลังจากลบปี 2023 แล้ว
----------------------------------------------------
ปี 2024: 19050 แถว
ปี 2025: 6445 แถว
```

บันทึกข้อมูลเพื่อนำไปใช้ต่อ

```
บันทึกไฟล์เรียบร้อยแล้ว -> lazadaapp_cleaned.csv
จำนวนแถวหลังคลีน: 25495
```

ส่วนที่ 2 การเตรียมและสำรวจคำจากรีวิว

อ่านไฟล์ lazadaapp_cleaned.csv และทำการแยกชุดข้อมูล

* 1) ชุดข้อมูลเต็ม (Full dataset) ใช้สำหรับงาน train ML / sentiment analysis

* 2) ชุดข้อมูลไม่ซ้ำ (Unique content) ใช้สำหรับ สำรวจคำและแยกประเด็น (Aspect)

```
โหลดไฟล์สำเร็จ
จำนวนแถวทั้งหมด (full): 25495
จำนวนแถวหลังลบ content ซ้ำ (unique): 20238
```

ตัวอย่าง

content
สวยงาม
สวยงาม
สินค้าตรงปก
สินค้าตรงปก
สวยงาม
สินค้าตรงปก
สวยงาม
สวยงาม
สินค้าตรงปก
สินค้าตรงปก
สินค้าตรงปก

สร้างสำเนาจากชุดข้อมูลที่ไม่ซ้ำ (df_unique) เพื่อใช้ในการสำรวจคำในข้อความรีวิว(content)

```
ข้อมูลที่ใช้สำหรับการสำรวจคำ / จัดประเด็น
จำนวนแถวทั้งหมด: 20238
จำนวนคอลัมน์: 3
ชื่อคอลัมน์: ['content', 'year', 'month']

ตัวอย่างข้อมูลดิบ:
```

	content
0	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ,,,ใช้คำว่าติดงอมแงมมากกว่า 😻
1	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ
2	ส่งข้อความมาให้สมัครแบบผ่อนชำระ แต่พอกดเข้าไปบอกคุณสมบัติไม่ตรงทั้งที่ยังไม่ได้ส่งอะไรถามจริงๆแล้วจะส่งข้อความมาทำเพื่ออะไรเสือกให้กดสมัครอีกทีปีหน้าช่วยตอบหน่อยนะ
3	ทำไมสมัครรอบ2มันเข้าระบบไม่ได้โทรไปที่ศูนย์บอกจะแก้ไขให้แต่รจนต้องให้คนอื่นสั่งให้
4	ใช้ง่าย มีสิ้นค้าที่มากให้ตัดสินใจเลือกได้อย่างคุ้มราคา คุณภาพครับ
5	โชว์โฆษณาหน้าต่างลอยดีนัก ลบแอพทิ้งซะเลย.. 👎
6	ของลาซ้าด้าดีมากยกเลิกได้เงินคืนเงินก็เร็ว
7	กุลบแล้สแอปนี้กากชิปหาย. ชอปปี้ดีกว่าเยอะ
8	ตรงปกดีค่ะรายละเอียดสินค้สชัดเจนดีค่ะ
9	สินค้าราคาไม่แพง

ทำความสะอาดข้อความ (Text Cleaning)

ทำความสะอาดข้อความรีวิว โดยลบอักขระที่ไม่เกี่ยวข้องกับการวิเคราะห์ภาษาไทย เช่น emoji, HTML tag, ตัวเลข และอักขระพิเศษ รวมถึงจัดการช่องว่างซ้ำ

เน้น “ความสะอาดของคำ” เพื่อการสำรวจ keyword

การปรับรูปแบบคำ (Word Normalization)

สำหรับลดความซ้ำซ้อนของตัวอักษร สระ และวรรณยุกต์ ซึ่งมักพบในรีวิวที่เขียนแบบไม่เป็นทางการ เช่น “ดีมากกก”, “ช้ามากกก”

การตัดคำภาษาไทย (Tokenization)

ใช้ตัดคำภาษาไทยด้วย PyThaiNLP (attacut) จากนั้นทำ normalization เพิ่มเติม ลบคำซ้ำ คำที่ไม่ต้องการ และ stopwords

เพื่อให้ได้ชุดคำที่เหมาะสมสำหรับการวิเคราะห์ประเด็น → ฟังก์ชัน tokenize พร้อมใช้งาน

ตรวจสอบผลลัพธ์การทำความสะอาด

แสดงตัวอย่างข้อความก่อนและหลังการทำความสะอาด รวมถึงผลการตัดคำ

ตารางเปรียบเทียบผลลัพธ์:

	content	clean_text	tokens
0	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ,,,ใช้คำว่าติดงอมแงมมากกว่า 🥰	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ใช้คำว่าติดงอมแงมมากกว่า	[แอ็บ, ผิดพลาด, ตอน, ถูกใจ, ลวม, ชอบ, ติด, งอมแงม, กว่า]
1	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	[คิวอาร์, ผิดพลาด, ปรับปรุง]
2	ส่งข้อความมาให้สมัครแบบผ่อนชำระ แต่พอกดเข้าไปบอกคุณสมบัติไม่ตรงทั้งที่ยังไม่ได้ส่งอะไรถามจริงๆแล้วจะส่งข้อความมาทำเพื่ออะไรเลือกให้กดสมัครอีกทีปีหน้าช่วยตอบหน่อยนะ	ส่งข้อความมาให้สมัครแบบผ่อนชำระ แต่พอกดเข้าไปบอกคุณสมบัติไม่ตรงทั้งที่ยังไม่ได้ส่งอะไรถามจริงๆแล้วจะส่งข้อความมาทำเพื่ออะไรเลือกให้กดสมัครอีกทีปีหน้าช่วยตอบหน่อยนะ	[ข้อความ, สมัคร, ผ่อน, ชำระ, พอกด, คุณสมบัติ, ถาม, ข้อความ, ทำ, เลือก, กด, สมัคร, ปี, หน้า, ตอบ]
3	ทำไมสมัครรอบ2มันเข้าระบบไม่ได้โทรไปที่ศูนย์บอกจะแก้ไขให้แต่รจนต้องให้คนอื่นสั่งให้	ทำไมสมัครรอบ มันเข้าระบบไม่ได้โทรไปที่ศูนย์บอกจะแก้ไขให้แต่รจนต้องให้คนอื่นสั่งให้	[สมัคร, รอบ, ระบบ, โทร, ศูนย์, แต่ร, คน, สั่ง]
4	ใช้ง่าย มีสิ้นค้าที่มากให้ตัดสินใจเลือกได้อย่างคุ้มราคา คุณภาพครับ	ใช้ง่าย มีสิ้นค้าที่มากให้ตัดสินใจเลือกได้อย่างคุ้มราคา คุณภาพครับ	[ค้า, ตัดสินใจ, เลือก, คุ้มราคา, คุณภาพ]
5	โชว์โฆษณาหน้าต่างลอยดีนัก ลบแอพทิ้งซะเลย..👎	โชว์โฆษณาหน้าต่างลอยดีนัก ลบแอพทิ้งซะเลย	[โชว์, โฆษณา, หน้าต่างลอย, ดี, ลบแอพ, ทิ้ง]

RMUTP

ประมวลผลทั้งชุดข้อมูล นำกระบวนการทำความสะอาดและตัดคำไปใช้กับข้อมูลรีวิวทั้งหมด

สร้าง tokens ให้ทั้งไฟล์เรียบร้อย

การนับคำและสำรวจคำที่พบบ่อย

รวมคำทั้งหมดจากรีวิวทุกข้อความเพื่อใช้วิเคราะห์ความถี่ของคำ

แสดงคำที่พบบ่อยที่สุด 200 คำ เพื่อใช้เป็นข้อมูลประกอบการคัดเลือกคำสำคัญในขั้นตอนถัดไป

```
('ซื้อ', 2359),
('ราคา', 2242),
('ลด', 2125),
('ชอบ', 1856),
('เงิน', 1797),
('โฆษณา', 1555),
('คืน', 1280),
('แอป', 1250),
```

สร้างตาราง df_words

สร้างตารางความถี่ของคำในรูปแบบ DataFrame เพื่อความสะดวกในการนำไปจัดหมวดประเด็น

```
df_words ถูกสร้างแล้ว: (9696, 2)
```

	word	count
0	ดี	8627
1	สินค้า	4745
2	สั่ง	3532
3	ซื้อ	2359
4	ราคา	2242

กำหนดหมวดประเด็นจากงานวิจัยเดิม อ้างอิงจากงานวิจัยของ Wanassawan และ Ekarat (2022) เรื่อง การวิเคราะห์ความคิดเห็นจากทวิตเตอร์ของลูกค้าบริษัทช้อปปี้ประเทศไทย

กำหนดหมวดประเด็นและคำสำคัญตามงานวิจัย เพื่อใช้เป็นกรอบเริ่มต้นในการวิเคราะห์ตรวจสอบว่าคำจากงานวิจัยพบในข้อมูลจริงหรือไม่

```python
# ---------------------- หมวดหมู่จากวิจัย ----------------------
topics = {
    "System": [
        "แอป","แอปลาซาด้า","แอปพลิเคชั่น","หน้าจอ","รวน","สมัคร","ไถ",
        "ชั่วคราว","ระบบ","เงิน","หน้าเว็บ","เว็บ","ตัดเงิน","บัตร","แคนเซิล",
        "ยกเลิก","พัง","ค้าง","ล่ม","เสีย","ไม่ได้","เด้ง","รอ","พัฒนา",
        "หักเงิน","คืนเงิน","ตัดบัตร","ใช้ยาก","ใช้งานง่าย","ไม่ตรง","โอนเงิน",
        "เครดิต","แก้ไข","ขัดข้อง","ฟื้น","จ่ายเงิน","ผ่อน","ปัญหา","โดนระงับ",
        "ตรวจสอบ","ขั้นตอน","เงินไม่เข้า","เติมเงิน","จ่ายไม่ได้","แบบใหม่",
        "แบบเก่า","บัตรเครดิต","บอท","อัพเดต","เงินคืน","บัญชี","อนุมัติ",
        "กดเงิน","อัตโนมัติ","ฟีด","โหมดดาร์ก","สถานะ","แฮ็ค","ตะกร้า",
        "แจ้งเตือน","ลิ้งก์","สะดวก","ระบบล่ม","โหลด","ปัดจอ","เสิร์ช",
        "ธุรกรรม","วงเงิน","วอลเล็ต"
    ],

    "Logistics": [
        "ไม่ติดต่อ","ยกเลิก","รอ","ช้า","นาน","ไม่ได้รับ","ไม่ได้สินค้า","ปัญหา",
        "ผู้ส่ง","พนักงานขนส่ง","ขนส่ง","บริการ","ไม่โทรมา","ส่งของ","ไม่มาส่ง",
        "ไม่ส่ง","สุภาพ","บอกทาง","เช็ค","ตรวจ","ที่อยู่","ส่งช้า","ส่งเร็ว",
        "ส่งไว","โทรมา","ไม่โทร","ไม่รับ","เลือกขนส่ง","เลือกบริษัทขนส่ง",
        "ค่าส่ง","เก็บปลายทาง","เลขพัสดุ","จ่าหน้า"
    ],

    "Company": [
        "ลาซาด้า","บริษัท","แอดมิน","คอลเซ็นเตอร์","เจ้าหน้าที่","พนักงาน",
        "ค่าบริการ","รับผิดชอบ","ติดต่อ","โกงเงิน","บัญชี","ดำเนินการ",
        "คุยกับพนักงาน","บริการ","แจ้ง","พรีเมียม","เมมเบอร์","แบน",
        "เลิกใช้","สื่อสาร","ร้องเรียน","เว็บไซต์","เบอร์","โทร","เมล",
        "สนใจ","เพิกเฉย","รอสาย","ตัดสาย","ด่วน","ศูนย์บริการ","ชดเชย",
        "องค์กร","ประทับใจ","แนะนำ","ชี้แจง","นโยบาย","สมาชิก","การตลาด",
        "โฆษณา","ลูกค้า","ผู้ใช้บริการ","แพลตฟอร์ม"
    ],

    "Store": [
        "ร้าน","ร้านค้า","ช้อป","ซื้อ","สั่ง","จากลาซาด้า","ไลฟ์","ไลฟ์สด",
        "ราคา","คุ้ม","คุ้มค่า","ไม่คุ้ม","แพง","ถูก","ลด","คุณภาพ",
        "ส่วนต่าง","ควรซื้อ","ไปต่ำ","พิกัด","รีวิว","สอย","พร้อมส่ง",
        "ค่าสั่งซื้อ","แม่ค้า","พ่อค้า","โกง","ผู้ขาย","แกง","ร้านเสื้อผ้า",
        "เสียเงิน","ขายดี","หมดไว","ปลอม","สินค้า","ของ"
    ],

    "Promotion": [
        "โค้ด","โค้ด","โค้ดลด","โค้ดลาซาด้า","กดไม่ทัน","ใช้ไม่ทัน","ค่าส่ง",
        "ลดราคา","ส่วนลด","โปรโมชั่น","โปร","โปรลด","ส่งฟรี","โค้ดส่งฟรี",
        "ใช้โค้ดไม่ได้","ขั้นต่ำ","ฟรี","แถม","เต็ม","แฟลชเซล","เมมเบอร์",
        "สิทธิ์","คอยน์","แคมเปญ","เหรียญ","ดีล","คูปอง","กิจกรรม"
    ]
}
```

```
หมวด: System
====================
คำที่พบในข้อมูล:
['แอป', 'แอปลาซาด้า', 'แอปพลิเคชั่น', 'รวน', 'สมัคร', 'ชั่วคราว', 'ระบบ', 'เงิน', 'เว็บ', 'บัตร', 'ยกเลิก', 'พัง', 'ค้าง', 'ล่ม', 'เด้ง',

 คำที่ไม่พบในข้อมูล:
['หน้าจอ', 'ไถ', 'หน้าเว็บ', 'ตัดเงิน', 'แคนเซิล', 'เสีย', 'ไม่ได้', 'หักเงิน', 'คืนเงิน', 'ตัดบัตร', 'ใช้ยาก', 'ใช้งานง่าย', 'ไม่ตรง', 'โอนเงิ

====================
หมวด: Logistics
====================
คำที่พบในข้อมูล:
['ยกเลิก', 'รอ', 'ปัญหา', 'ขนส่ง', 'บริการ', 'สุภาพ', 'เช็ค', 'ตรวจ', 'ส่งไว', 'เลขพัสดุ']

 คำที่ไม่พบในข้อมูล:
['ไม่ติดต่อ', 'ช้า', 'นาน', 'ไม่ได้รับ', 'ไม่ได้สินค้า', 'ผู้ส่ง', 'พนักงานขนส่ง', 'ไม่โทรมา', 'ส่งของ', 'ไม่มาส่ง', 'ไม่ส่ง', 'บอกทาง', 'ที่อยู่

====================
หมวด: Company
====================
คำที่พบในข้อมูล:
['ลาซาด้า', 'บริษัท', 'แอดมิน', 'เจ้าหน้าที่', 'พนักงาน', 'รับผิดชอบ', 'ติดต่อ', 'บัญชี', 'ดำเนินการ', 'บริการ', 'แจ้ง', 'พรีเมียม', 'แบน',
...
['โค้ด', 'โค้ด', 'โปรโมชั่น', 'โปร', 'โปรลด', 'ฟรี', 'แถม', 'เต็ม', 'แฟลชเซล', 'สิทธิ์', 'แคมเปญ', 'เหรียญ', 'ดีล', 'คูปอง', 'กิจกรรม

 คำที่ไม่พบในข้อมูล:
['โค้ดลด', 'โค้ดลาซาด้า', 'กดไม่ทัน', 'ใช้ไม่ทัน', 'ค่าส่ง', 'ลดราคา', 'ส่วนลด', 'ส่งฟรี', 'โค้ดส่งฟรี', 'ใช้โค้ดไม่ได้', 'ขั้นต่ำ', 'เมมเบอร์',
```

RMUTP

คัดเลือกเฉพาะคำจากงานวิจัยที่พบจริงในข้อมูล

คัดเลือกเฉพาะคำสำคัญจากงานวิจัยที่พบในข้อมูลจริง เพื่อนำมาใช้เป็นชุดคำเริ่มต้นในการจัดหมวดประเด็น

วิเคราะห์คำอื่น ๆ จากข้อมูลจริงที่อยู่นอกกรอบวิจัย

วิเคราะห์คำที่พบบ่อยในข้อมูลรีวิว เพื่อค้นหาคำเพิ่มเติมที่อาจสะท้อนประเด็นสำคัญจากมุมมองผู้ใช้จริง จัดกลุ่มคำตามหมวดประเด็น เพื่อดูการกระจายของคำในแต่ละประเด็น ตรวจสอบคำที่ยังไม่ถูกจัดหมวด เพื่อพิจารณาว่าสามารถเชื่อมโยงกับประเด็นใดได้บ้าง

```
df_words created: (9696, 2)
```

ประเด็น:
- System
- Logistics
- Company
- Store
- Promotion
- อื่นๆ

	word	count	lazada_topics
7	เงิน	1797	System
10	แอป	1250	System
12	สะดวก	1166	System
30	เด้ง	674	System
33	รอ	625	System
...	...	...	...
1793	ธุรกรรม	3	System

```python
# ---------------- Lazada Topic (คำที่คัดแล้วว่าเจอในข้อมูลจริงที่อ้างอิงจากงานวิจัย) ----------
lazada_topics = {
    "System": [
        'แอป', 'แอปลาซาด้า', 'แอปพลิเคชั่น', 'รวน', 'สมัคร',
        'ใถ', 'ชั่วคราว', 'ระบบ', 'เงิน', 'เว็บ', 'บัตร', 'ยกเลิก',
        'ฟัง', 'ค้าง', 'ล่ม', 'เด้ง', 'รอ', 'พัฒนา', 'เครดิต',
        'ขัดข้อง', 'ปัญหา', 'โดนระงับ', 'ตรวจสอบ', 'ขั้นตอน',
        'บอท', 'อัพเดต', 'บัญชี', 'อนุมัติ', 'อัตโนมัติ', 'ฟีด',
        'สถานะ', 'ตะกร้า', 'สะดวก', 'โหลด', 'เสิร์ช', 'ธุรกรรม',
        'วงเงิน', 'วอลเล็ต'],

    "Logistics": [
        'ยกเลิก', 'รอ', 'ปัญหา', 'ขนส่ง', 'บริการ',
        'สุภาพ', 'เช็ค', 'ตรวจ', 'ส่งไว', 'เลขพัสดุ'
    ],

    "Company": [
        'ลาซาด้า', 'บริษัท', 'แอดมิน', 'เจ้าหน้าที่', 'พนักงาน',
        'รับผิดชอบ', 'ติดต่อ', 'บัญชี', 'ดำเนินการ', 'บริการ',
        'แจ้ง', 'พรีเมียม', 'แบน', 'สื่อสาร', 'ร้องเรียน', 'เว็บไซต์',
        'เบอร์', 'โทร', 'เมล', 'สนใจ', 'เพิกเฉย', 'ด่วน',
        'ชดเชย', 'องค์กร', 'ประทับใจ', 'แนะนำ', 'ชี้แจง', 'นโยบาย',
        'สมาชิก', 'โฆษณา', 'ลูกค้า', 'แพลตฟอร์ม'],

    "Store": [
        'ร้าน', 'ร้านค้า', 'ช้อป', 'ซื้อ', 'สั่ง', 'ไลฟ์', 'ราคา',
        'คุ้ม', 'แพง', 'ลด', 'คุณภาพ', 'พิกัด', 'รีวิว', 'สอย',
        'แม่ค้า', 'พ่อค้า', 'โกง', 'แกง', 'ปลอม', 'สินค้า'
    ],

    "Promotion": [
        'โค้ด', 'โค้ด', 'โปรโมชั่น', 'โปร', 'โปรลด', 'ฟรี', 'แถม',
        'เต็ม', 'สิทธิ์', 'คอยน์', 'แคมเปญ', 'เหรียญ', 'ดีล', 'คูปอง', 'กิจกรรม'
    ]
}
```

RMUTP

สร้างพจนานุกรมประเด็นจากการผสานคำสำคัญที่อ้างอิงงานวิจัยและคำที่พบจริงจากข้อมูลรีวิว

```
aspect_dict = {

    "System": [
     'กด', 'กดใส่', 'กดิกา', 'กรอก', 'กระตุก', 'กลับคืน', 'กลไก', 'กล้อง', 'กากบาท', 'การ์ด',
     'ข้อมูล', 'ครอบคลุม', 'คลิก', 'คลิป', 'ควบคู่', 'คอนเทนต์', 'คัดลอก', 'คำเสิร์ช', 'คีย์เวิร์ด', 'คืบหน้า',
     'คัน', 'ค้นหา', 'ค้าง', 'จอหลัก','....','....'

    ],

    "Logistics": [
     'กล่อง', 'การขนส่ง', 'ขนส่ง', 'ขนส่งทาง', 'ขนส่งพอ', 'ขนส่งอะรัย', 'ขนส่งไว', 'ขับไว', 'คลัง', 'คัดแยก',
     'จอง', 'ฉีกขาด', 'ดีขนส่ง', 'ตกค้าง', 'ตรวจ', 'ตรวจเช็ค', 'ติดขัด', 'ติดค้าง', 'ติดตาม', 'ต่อเนื่อง',
     'ถ่าย', 'ทำขนส่ง', 'นัด', '....', '....'
    ],

    "Company": [
     'การค้า', 'การันตี', 'กำกับ', 'ก่อกวน', 'กับริการ', 'ขอร้องเรียน', 'ขโมย', 'คอมเพลน', 'คอมเม้นต์', 'คอมเม้นท์',
     'คอลเซนเตอร์', 'คืนตัง', 'คุ้มครอง', 'คู่แข่ง', 'ชดเชย', 'ชาด้า', 'ดำเนินการ', 'ดีงาม', 'ดูแลรักษา', 'ตอบ',
     'ตอบสนอง',  '....', '....'
    ],

    "Store": [
     'กระทบ', 'กระเป๋า', 'กวนใจ', 'กางเกง', 'กุ้ง', 'ขนาด', 'ของขวัญ', 'ชัดเงา', 'ขาย', 'ข้าว',
     'คัดสินค้า', 'คัดเลือก', 'คิวอาร์โค้ด', 'คืน', 'คุณภาพ', 'คุณภาพบาง', 'คุ้มช้อปออนไลน์', 'คุณภาพ', 'คูปองลูกค้า', 'ค้าซื่อสัตย์',
     'จักรยาน', 'จัดซื้อ',  '....', '....'
    ],

    "Promotion": [
     'กระหน่ำ', 'กั๊กโค้ด', 'กิจกรรม', 'กินโค้ด', 'ของขวัญเลือก', 'คะแนน', 'คุปอง', 'คูปอง', 'คูปองกี่', 'คูปองคืน',
     'คูปองซื้อ', 'คูปองดี', 'คูปองยาก', 'คูปองเงิน', 'คูปองเจก', 'คูปองเหรียน', 'คูปองโสน', 'คูปองใช้', 'จริงโค้ด', 'ฉ่ำโค้ด',
     'ชำระ', 'ดีล', 'ดีลสินค้า', 'บางโค้ด', 'บาท', 'ประหยัด',  '....', '....'
    }
```

ตรวจสอบคำใน aspect_dict ว่ามีจริงในข้อมูล

```
 จำนวน token ไม่ซ้ำทั้งหมดในรีวิว : 10050

==================================================
 ASPECT : System

คำที่ไม่พบในข้อมูลจริง:
ทุกคำพบในข้อมูล

คำที่พบในข้อมูลจริง:
['กด', 'กดใส่', 'กดิกา', 'กรอก', 'กระตุก', 'กลับคืน', 'กลไก', 'กล้อง', 'กากบาท', 'การ์ด', 'ข้อมูล', 'ครอบคลุม'

==================================================
 ASPECT : Logistics

คำที่ไม่พบในข้อมูลจริง:
ทุกคำพบในข้อมูล

คำที่พบในข้อมูลจริง:
['กล่อง', 'การขนส่ง', 'ขนส่ง', 'ขนส่งทาง', 'ขนส่งพอ', 'ขนส่งอะรัย', 'ขนส่งไว', 'ขับไว', 'คลัง', 'คัดแยก', 'จอง'

==================================================
 ASPECT : Company

คำที่ไม่พบในข้อมูลจริง:
ทุกคำพบในข้อมูล
...
ทุกคำพบในข้อมูล

คำที่พบในข้อมูลจริง:
['กระหน่ำ', 'กั๊กโค้ด', 'กิจกรรม', 'กินโค้ด', 'ของขวัญเลือก', 'คะแนน', 'คุปอง', 'คูปอง', 'คูปองกี่', 'คูปองคืน', 'คูป
```

ส่วนที่ 3 การจำแนกประเด็นด้วย Machine Learning (Naïve Bayes & RF)

ส่วนนี้มีเป้าหมายเพื่อจำแนกประเด็นที่ผู้ใช้พูดถึงในรีวิวโดยเป็นการจำแนกแบบ Multi-label ระดับประโยคเนื่องจากไม่มี label จริงจากข้อมูล จึงใช้วิธี Keyword-based labeling เพื่อสร้าง labelแล้วนำข้อมูลดังกล่าวไปฝึกและเปรียบเทียบโมเดล Naïve Bayes และ Random Forest

ข้อมูลทั้งหมดในไฟล์ (ชุดข้อมูลเต็ม)
จำนวนแถว: 25495
จำนวนคอลัมน์: 13

	reviewId	userName	userImage	content	score	thumbsUpCount	reviewCreatedVersion	at	replyContent	repliedAt	appVersion	year	month
0	cb2a5ad0-b0ee-442b-be21-8c8d09c2089b	[redacted]	https://play-lh.googleusercontent.com/a-/ALV-UjVrVxCdOJxHPpJ0RPNYHF9GiHrUbzkH8V0aI3YENQLj0FV59WIV	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนี่ยพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ...ใช้คำว่าผิดงอมแงมมากกว่า 🥰	5	0	NaN	2025-11-30 16:01:52	[redacted] ดีใจที่คุณเริ่มใช้งานแอปได้คล่องขึ้นและสนุกกับการช้อปปิ้ง! ขอบคุณที่แบ่งปันประสบการณ์นี้นะ หวังว่าคุณจะพบกับข้อเสนอที่น่าตื่นเต้นในครั้งต่อไปนะ!	2025-11-30 16:10:26	NaN	2025	11
1	60e79c20-c630-4560-861e-301ff41c7a08	[redacted]	https://play-lh.googleusercontent.com/a/ACg8ocLeOfRqDI8LsZ9HKZGyyYc3jud8ScUJeqOKHugkgVseQjTJIABX=mo	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	3	0	7.88.0	2025-11-30 13:03:14	ขอบคุณสำหรับความคิดเห็นที่มีค่าของคุณนะคะ คุณ [redacted] เราเห็นว่าคิวอาร์โค้ดมีปัญหาบ่อยครั้ง ซึ่งเป็นสิ่งที่สำคัญมาก เราได้บันทึกข้อเสนอแนะของคุณไว้เพื่อให้ทีมงานพิจารณาเพิ่มเติมนะคะ หากคุณมีข้อมูลเพิ่มเติมเกี่ยวกับปัญหานี้ สามารถใช้ตัวเลือกสนับสนุนในแอปได้เลยค่ะ หวังว่าคุณจะมีประสบการณ์ที่ดีขึ้นในอนาคตนะคะ!	2025-11-30 13:10:30	7.88.0	2025	11
2	c1a91431-36aa-477a-bd00-35094c90f7a1	[redacted]	https://play-lh.googleusercontent.com/a/ACg8ocLbvpmzxufZ_oEXP7556dOWUZTbOT1x-qqJsZfwj9iDEd5eJQ=mo	ส่งข้อความมาให้สมัครแบบผ่อนชำระ แต่พอกดเข้าไปบอกคุณสมบัติไม่ตรงทั้งที่ยังไม่ได้ส่งอะไรถามจริงๆแล้วจะส่งข้อความมาทำเพื่ออะไรเลือกให้กดสมัครอีกทีปีหน้าช่วยตอบหน่อยนะ	1	0	7.88.0	2025-11-30 09:07:27	สวัสดีค่ะ [redacted] ขอบคุณที่แชร์ความคิดเห็นนะคะ เราเข้าใจว่าการสมัครแบบผ่อนชำระที่ไม่ตรงตามคุณสมบัติที่แจ้งไว้ทำให้คุณรู้สึกไม่สะดวก เราได้บันทึกความคิดเห็นของคุณและส่งต่อให้ทีมงานพิจารณา หากคุณมีข้อมูลเพิ่มเติมเกี่ยวกับปัญหานี้ สามารถใช้ตัวเลือกสนับสนุนในแอปได้เลยนะ หวังว่าคุณจะมีประสบการณ์ที่ดีขึ้นในอนาคตคะ!	2025-11-30 09:20:29	7.88.0	2025	11

ข้อมูลที่ใช้สำหรับการวิเคราะห์ (df_content)
จำนวนแถว: 25495

	content	year	month
0	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนี่ยพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ...ใช้คำว่าผิดงอมแงมมากกว่า 🥰	2025	11
1	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	2025	11
2	ส่งข้อความมาให้สมัครแบบผ่อนชำระ แต่พอกดเข้าไปบอกคุณสมบัติไม่ตรงทั้งที่ยังไม่ได้ส่งอะไรถามจริงๆแล้วจะส่งข้อความมาทำเพื่ออะไรเลือกให้กดสมัครอีกทีปีหน้าช่วยตอบหน่อยนะ	2025	11
3	ทำไมสมัครรอบ2มันเข้าระบบไม่ได้โทรไปที่ศูนย์บอกจะแก้ไขให้แต่รจนต้องให้คนอื่นสั่งให้	2025	11
4	ใช้ง่าย มีสิ้นค้าที่มากให้ตัดสินใจเลือกได้อย่างคุ้มราคา คุณภาพครับ	2025	11
5	โชว์โฆษณาหน้าต่างลอยดีนัก ลบแอพทิ้งซะเลย..👎	2025	11
6	ของลาซ้าด้าดีมากยกเลิกได้เงินคืนเงินก็เร็ว	2025	11
7	คุลบแล้สแอปนี้กากชิปหาย. ชอปปี้ดีกว่าเยอะ	2025	11
8	ตรงปกดีค่ะรายละเอียดสินค้สชัดเจนดีค่ะ	2025	11
9	สินค้าราคาไม่แพง	2025	11

ทำความสะอาดข้อความ (Text Cleaning)

	content	tokens
0	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ,,,ใช้คำว่าติดงอมแงมมากก่วา 🥰	[แอ็บ, ผิดพลาด, ตอน, ถูกใจ, ลวม, ชอบ, ติด, งอมแงม, ก่วา]
1	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	[คิวอาร์, ผิดพลาด, ปรับปรุง]
2	ส่งข้อความมาให้สมัครแบบผ่อนชำระ แต่พอกดเข้าไปบอกคุณสมบัติไม่ตรงทั้งที่ยังไม่ได้ส่งอะไรถามจริงๆแล้วจะส่งข้อความมาทำเพื่ออะไรเสือกให้กดสมัครอีกทีปีหน้าช่วยตอบหน่อยนะ	[ข้อความ, สมัคร, ผ่อน, ชำระ, พอกด, คุณสมบัติ, ถาม, ข้อความ, ทำ, เสือก, กด, สมัคร, ปี, หน้า, ตอบ]
3	ทำไมสมัครรอบ2มันเข้าระบบไม่ได้โทรไปที่ศูนย์บอกจะแก้ไขให้แต่รจนต้องให้คนอื่นสั่งให้	[สมัคร, รอบ, ระบบ, โทร, ศูนย์, แต่ร, คน, สั่ง]
4	ใช้ง่าย มีสิ้นค้าที่มากให้ตัดสินใจเลือกได้อย่างคุ้มราคา คุณภาพครับ	[ค้า, ตัดสินใจ, เลือก, คุ้มราคา, คุณภาพ]

สร้าง label จากคำสำคัญ (Keyword-based labeling)

*กำหนด หมวดประเด็น (Aspect) ที่ต้องการวิเคราะห์

*เพิ่มหมวด Other เพื่อรองรับรีวิวที่ไม่เข้าเกณฑ์ใดเลย

*รับ input เป็น tokens ของข้อความ

*ตรวจสอบว่า token ใดตรงกับคำใน aspect_dict ถ้าพบ → ใส่หมวดนั้น ถ้าไม่พบเลย → จัดเป็น "Other"

วิเคราะห์จำนวนรีวิวในแต่ละประเด็น

นำฟังก์ชันไปใช้กับ รีวิวทั้งก้อน เพื่อตรวจสอบว่าหมวดไหนมีจำนวนรีวิวเท่าไหร่

จำนวนรีวิวในแต่ละหมวด (รวมหมวดอื่นๆ):

	review_count
Store	9143
Other	9034
System	6576
Company	6165
Promotion	4406
Logistics	2446

แยกรีวิวเป็นระดับประโยค

* รีวิว 1 อัน อาจพูดหลายประเด็น การจำแนกระดับประโยคทำให้แม่นยำกว่า
* สร้าง dataset ใหม่ในระดับ sentence เพื่อเพิ่มความแม่นยำในการจำแนก aspect
* คลีนประโยคใหม่
* ลบประโยคที่ว่างหลังคลีน

df_sentences สร้างสำเร็จ จำนวนแถว: 39028

sentence_clean	System	Logistics	Company	Store	Promotion	Other
แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง	1	0	0	0	0	0
ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร	0	0	0	0	0	1
ลวมๆแล้วชอบ	0	0	0	0	0	1
ใช้คำว่าดึงอมแงมมากกว่า	0	0	0	0	0	1
คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	1	0	0	0	0	0

Tokenize ประโยค (แปลงข้อความเป็นคำ)

* นำข้อความที่ผ่านการ clean แล้วในแต่ละประโยคแยกออกเป็น รายการคำ (tokens)
* ผลลัพธ์ของแต่ละแถวจะเป็น list ของคำ
* ตรวจว่าประโยคกล่าวถึง ประเด็น (aspect) ใดบ้าง

รวมคำกลับเป็นข้อความ (เตรียมข้อมูลเข้าโมเดล)

* นำ tokens ที่อยู่ในรูปแบบ list ของคำ มาต่อกลับเป็นข้อความเดียว
* คั่นแต่ละคำด้วยเว้นวรรค เพื่อให้โมเดลอย่าง TF-IDF สามารถอ่านและประมวลผลได้

เตรียมข้อมูล X (ข้อความสำหรับเทรนโมเดล)

* กำหนดคอลัมน์ข้อความที่รวมคำแล้วเป็นตัวแปร X

```
ขนาดข้อมูล X: (39028,)
ขนาด label y: (39028, 6)

จำนวนข้อมูลของแต่ละหมวด:

System        8350
Logistics     2891
Company       7220
Store        11141
Promotion     5035
Other        15863
dtype: int64

Train size: 31222
Test size: 7806
```

ขั้นตอนเตรียมข้อมูลให้โมเดล Random Forest หรือ Naive Bayes ใช้ได้ โดยแปลงข้อความเป็นตัวเลข TF-IDF

แปลงข้อความเป็นตัวเลขด้วย TF-IDF

* TF-IDF จะดูว่าคำไหนสำคัญในประโยคนั้น และไม่ใช่คำที่ปรากฏบ่อยเกินไปในทุกประโยค ทำให้โมเดลโฟกัสคำที่ช่วยแยกประเด็นได้จริง

กำหนด min_df=5 เลือกใช้เฉพาะคำที่ปรากฏอย่างน้อย 5 ประโยค

* ตัดคำที่เจอน้อยมาก ซึ่งมักเป็นคำพิมพ์ผิดหรือไม่สำคัญ

* ช่วยลด noise และทำให้โมเดลเสถียรมากขึ้น

กำหนด ngram_range=(1,2)

* ใช้ทั้งคำเดี่ยว (unigram) และคำคู่ (bigram)

* ช่วยให้โมเดลเข้าใจความหมายเป็นวลี เช่น จาก "คิวอาร์ ผิดพลาด ปรับปรุง" เป็น คิวอาร์ ผิดพลาด ทำให้เห็นประเด็นชัดยิ่งขึ้น

- หลังจากการแปลงด้วย TF-IDF ข้อมูลจะอยู่ในรูปแบบเชิงตัวเลข ซึ่งเป็นรูปแบบที่โมเดล Machine Learning สามารถประมวลผลได้โดยตรง

```
TF-IDF shape (train): (31222, 2822)
จำนวนคำทั้งหมดใน vocabulary: 2822
ตัวอย่าง X (tokens_join):
0                                                แอ็บ ผิดพลาด
1                                                   ตอน ถูกใจ
2                                                    ลวม ชอบ
3                                              ติด งอมแงม กว่า
5                                       คิวอาร์ ผิดพลาด ปรับปรุง
6                                        ข้อความ สมัคร ผ่อน ชำระ
7     พอกด คุณสมบัติ ถาม ข้อความ ทำ เลือก กด สมัคร ปี หน้า ตอบ
8                          สมัคร รอบ ระบบ โทร ศูนย์ แต่ร คน สั่ง
9
10                                     ค้า ตัดสินใจ เลือก คุ้มราคา
Name: tokens_join, dtype: object
ตัวอย่าง y (one-hot per aspect):
    System  Logistics  Company  Store  Promotion  Other
0        1          0        0      0          0      0
1        0          0        0      0          0      1
2        0          0        0      0          0      1
3        0          0        0      0          0      1
5        1          0        0      0          0      0
6        1          0        0      0          1      0
7        1          0        1      0          0      0
8        1          0        1      0          0      0
9        0          0        0      0          0      1
10       0          0        0      1          0      0
```

เอาข้อมูลข้อความที่แปลงเป็น TF-IDF แล้ว ไปฝึกโมเดล Naïve Bayes และ Random Forest

ผลลัพธ์การประเมินประสิทธิภาพของโมเดล Random Forest พบว่าโมเดลมีประสิทธิภาพในการจำแนกประเด็นความคิดเห็นอยู่ในระดับสูงมาก โดยมีค่า precision, recall และ f1-score สูงเกือบทุกหมวดประเด็น เมื่อเปรียบเทียบกับโมเดล Naïve Bayes พบว่า Random Forest ให้ค่าความแม่นยำที่สูงกว่าอย่างชัดเจน โดยเฉพาะในหมวด Logistics, Promotion และ Other ซึ่งเป็นหมวดที่มีความหลากหลายของข้อความ เมื่อพิจารณาค่า Accuracy รายหมวด พบว่าโมเดลมีค่า Accuracy มากกว่าร้อยละ 99 ในทุกหมวดประเด็น และมีค่า Accuracy เฉลี่ยทั้งแบบ Macro และ Micro เท่ากับ 0.9943 ซึ่งสะท้อนให้เห็นว่าโมเดล Random Forest สามารถเรียนรู้รูปแบบของข้อมูลจากเวกเตอร์ TF-IDF ได้อย่างมีประสิทธิภาพ และมีความเหมาะสมสำหรับนำไปใช้ในการวิเคราะห์และจำแนกประเด็นความคิดเห็นในงานวิจัยนี้

```
เริ่มเทรน Naive Bayes ...
เทรนเสร็จแล้ว
===== รายงานผล Naive Bayes (multi-label) =====

              precision    recall  f1-score   support

      System     0.9740    0.8816    0.9255      1698
   Logistics     0.9929    0.7360    0.8454       572
     Company     0.9976    0.8538    0.9201      1477
       Store     0.9962    0.9221    0.9577      2271
   Promotion     0.9950    0.8283    0.9040       961
       Other     0.9656    0.7289    0.8307      3157

   micro avg     0.9835    0.8258    0.8978     10136
   macro avg     0.9869    0.8251    0.8972     10136
weighted avg     0.9829    0.8258    0.8958     10136
 samples avg     0.8636    0.8342    0.8429     10136


Accuracy ต่อแต่ละหมวด (NB):
System: 0.9691
Logistics: 0.9803
Company: 0.9719
Store: 0.9763
Promotion: 0.9783
Other: 0.8798

Accuracy เฉลี่ยแบบ Macro (NB): 0.9593
Accuracy แบบ Micro (NB): 0.9593
```

```
เริ่มเทรนโมเดล Random Forest ...
เทรนเสร็จแล้ว
===== รายงานผลรวมทุกหมวด (multi-label) =====

              precision    recall  f1-score   support

      System     0.9988    0.9582    0.9781      1698
   Logistics     0.9926    0.9371    0.9640       572
     Company     1.0000    0.9722    0.9859      1477
       Store     1.0000    0.9868    0.9934      2271
   Promotion     0.9989    0.9729    0.9858       961
       Other     0.9743    0.9965    0.9853      3157

   micro avg     0.9910    0.9788    0.9849     10136
   macro avg     0.9941    0.9706    0.9821     10136
weighted avg     0.9913    0.9788    0.9848     10136
 samples avg     0.9864    0.9814    0.9828     10136


Accuracy ต่อแต่ละหมวด:
System: 0.9906
Logistics: 0.9949
Company: 0.9947
Store: 0.9962
Promotion: 0.9965
Other: 0.9880

Accuracy เฉลี่ยแบบ Macro: 0.9935
Accuracy แบบ Micro (รวมทุก label): 0.9935
```

จัดเก็บผลการทำนาย Aspect จากโมเดล Random Forest

บันทึกไฟล์ไปใช้ในขั้นตอนถัดไป

บันทึกโมเดล ✓ บันทึกไฟล์ `df_sentences_for_use.csv` เรียบร้อย

ส่วนที่ 4 การวิเคราะห์ความคิดเห็นเชิงบวก–เชิงลบ–เป็นกลาง

โหลดข้อมูล และเตรียม DataFrame

```
โหลดไฟล์สำเร็จ
จำนวนแถว        : 39028
จำนวนคอลัมน์: 13
```

	year	month	review_text	sentence_raw	sentence_clean	tokens_join	aspects	RF_System	RF_Logistics	RF_Company	RF_Store	RF_Promotion	RF_Other
0	2025	11	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ,,,ใช้คำว่าติดงอมแงมมากก่วา 🥰	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆ อย่าง	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆ อย่าง	แอ็บ ผิดพลาด	['System']	1	0	0	0	0	0
1	2025	11	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ,,,ใช้คำว่าติดงอมแงมมากก่วา 🥰	ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของ ถูกใจพอสมควร	ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของ ถูกใจพอสมควร	ตอน ถูกใจ	['Other']	0	0	0	0	0	1
2	2025	11	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ,,,ใช้คำว่าติดงอมแงมมากก่วา 🥰	ลวมๆแล้วชอบ	ลวมๆแล้วชอบ	ลวม ชอบ	['Other']	0	0	0	0	0	1
3	2025	11	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร ลวมๆแล้วชอบ ,,,ใช้คำว่าติดงอมแงมมากก่วา 🥰	,,,ใช้คำว่าติดงอมแงมมากก่วา	ใช้คำว่าติดงอมแงมมากก่วา	ติด งอมแงม ก่วา	['Other']	0	0	0	0	0	1

โหลดโมเดล WangchanBERTa สำหรับ Sentiment Analysis

* ใช้ WangchanBERTa ที่ถูก fine-tune สำหรับวิเคราะห์อารมณ์ (positive/negative/neutral)
* ทำงานระดับ sentence-level

```
 warnings.warn(
Model id2label (mapping จริง): {0: 'pos', 1: 'neu', 2: 'neg'}
```

ฟังก์ชันทำนาย Sentiment แบบ batch

* รับรายการประโยคเป็น input
* ใช้ tokenizer แปลงประโยคเป็น input ของโมเดล
* คืนค่าเป็น list ของ sentiment (pos, neg, neu)

เตรียมข้อความสำหรับโมเดล

* ใช้คอลัมน์ sentence_clean
* แปลงเป็น list ของ string เพื่อส่งเข้าโมเดล

ทำนาย sentiment และเก็บผลลัพธ์

* เพิ่มคอลัมน์ใหม่ sentiment_pred
* เก็บผลเป็น pos/neg/neu

```
เริ่มทำนายทั้งหมด = 39028 ประโยค
Processed 39028/39028
ทำนายเสร็จแล้ว!
```

```
===== ตัวอย่างผลลัพธ์การวิเคราะห์อารมณ์ (ระดับประโยค) =====
```

	sentence_clean	sentiment_pred
0	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง	neg
1	ตอนนี้เนียพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร	neu
2	ลวมๆแล้วชอบ	pos
3	ใช้คำว่าติดงอมแงมมากก่วา	neu
4	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	neg
...	...	...
15	ชอปปี้ดีกว่าเยอะ	neg
16	ตรงปกดีค่ะรายละเอียดสินค้าชัดเจนดีค่ะ	pos
17	สินค้าราคาไม่แพง	pos
18	แอปโคตรห่วยจะสมัครเครดิต	neg
19	ถ่ายหน้าไม่ผ่านสักที	neg

ทำการเปลี่ยนชื่อ Sentiment_pred

	sentence	sentiment_pred	sentiment_display
0	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง	neg	Negative
1	ตอนนี้เนี่ยพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร	neu	Neutral
2	ลวมๆแล้วชอบ	pos	Positive
3	ใช้คำว่าติดงอมแงมมากกว่า	neu	Neutral
4	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	neg	Negative

ดูว่าประเด็นถูกพูดถึงด้วยอารมณ์บวก ลบ หรือกลาง เท่าไหร่

```
===== Aspect + Sentiment Matrix =====
```

	Positive	Negative	Neutral	Total
System	1407	4671	2239	8317
Logistics	396	1898	588	2882
Company	3402	2365	1425	7192
Store	4809	3163	3133	11105
Promotion	1837	1737	1445	5019

จำนวนและ % ของแต่ละ sentiment

```
===== จำนวนความคิดเห็นในแต่ละอารมณ์ =====

sentiment_pred
pos    15022
neu    12833
neg    11173
Name: count, dtype: int64

===== สัดส่วนความคิดเห็น (%) =====

sentiment_pred
pos    38.49
neu    32.88
neg    28.63
Name: proportion, dtype: float64
```

กำหนดรายชื่อประเด็น (aspects) ที่ต้องการใช้งาน

* เลือกเฉพาะคอลัมน์ที่จำเป็นจาก df_sentences ได้แก่ ปี เดือน ประโยคจริง อารมณ์ และผลการจำแนกประเด็นจาก Random Forest

* สร้าง DataFrame ใหม่สำหรับส่งออกข้อมูล ✓ Export พร้อม year / month สำหรับ Power BI

```
✓ โหลดไฟล์ aspect_sentiment_per_sentence.csv สำเร็จ
จำนวนแถว: 39028
จำนวนคอลัมน์: 9
```

	year	month	Sentence	Sentiment	System	Logistics	Company	Store	Promotion
0	2025	11	แรกๆใช้แอ็บไม่เป็นก็ผิดพลาดหลายๆอย่าง	Negative	1	0	0	0	0
1	2025	11	ตอนนี้เนี่ยพอเป็นนิดหน่อยเลยได้ของถูกใจพอสมควร	Neutral	0	0	0	0	0
2	2025	11	ลวมๆแล้วชอบ	Positive	0	0	0	0	0
3	2025	11	ใช้คำว่าติดงอมแงมมากกว่า	Neutral	0	0	0	0	0
4	2025	11	คิวอาร์ผิดพลาดบ่อยมากปรับปรุงด้วยค่ะ	Negative	1	0	0	0	0
5	2025	11	ส่งข้อความมาให้สมัครแบบผ่อนชำระ	Neutral	1	0	0	0	1
6	2025	11	แต่พอกดเข้าไปบอกคุณสมบัติไม่ตรงทั้งที่ยังไม่ได้ส่งอะไรถามจริงๆแล้วจะส่งข้อความมาทำเพื่ออะไรเลือกให้กดสมัครอีกทีปีหน้าช่วยตอบหน่อยนะ	Negative	1	0	1	0	0
7	2025	11	ทำไมสมัครรอบ2มันเข้าระบบไม่ได้โทรไปที่ศูนย์บอกจะแก้ไขให้แต่รจนต้องให้คนอื่นสั่งให้	Negative	1	0	1	0	0
8	2025	11	ใช้ง่าย	Neutral	0	0	0	0	0
9	2025	11	มีสิ้นค้าที่มากให้ตัดสินใจเลือกได้อย่างคุ้มราคา	Positive	0	0	0	1	0

RMUTP

การนำผลลัพธ์จากการวิเคราะห์ไปใช้ในการสร้าง Dashboard

นำข้อมูลรีวิวจาก Google Play Store ของแอป Lazada จำนวน 39,028 ประโยค มาวิเคราะห์และแปลงผลลัพธ์เป็น Dashboard บน Power BI เพื่อให้เห็นภาพรวมความคิดเห็นของผู้ใช้งานได้อย่างชัดเจน

เพิ่มคอลัมน์ Aspect

จากผลการทำนายของโมเดล เพื่อให้ง่ายต่อการแยก 1ประโยค 1ประเด็น เพื่อนำข้อมูลเข้าสู่ขั้นตอนการทำแดชบอร์ด

	A	B	C	D	E	F	G	H	I	J	K
1	year	month	Sentence	Sentiment	System	Logistics	Company	Store	Promotion	Aspect	Topic
2	2025	11	คุณภาพครับ	Positive	0	0	0	1	0	Store	คุณภาพ
3	2025	11	โชว์โฆษณาหน้าต่างลอยดีนัก	Neutral	1	0	0	0	0	System	โฆษณา
4	2025	11	ของลาช้าด้าดีมากยกเลิกได้เงินคืนเงินก็เร็ว	Positive	0	1	0	1	0	Logistics, Store	การยกเลิกคำสั่งซื้อ
5	2025	11	ตรงปกดีค่ะรายละเอียดสินค้สชัดเจนดีค่ะ	Positive	0	0	0	1	0	Store	สินค้าตรงปก
6	2025	11	สินค้าราคาไม่แพง	Positive	0	0	1	1	0	Company, Store	ราคา
7	2025	11	การลบแอพและการถอนการติดตั้งเกิดจากการที่โฆษณาก่อกวนในยูทูบมาเกินไปจนน่ารำคาญ	Negative	1	0	1	0	0	System, Company	โฆษณา
8	2025	11	สวยงาม	Positive	0	0	0	1	0	Store	อื่นๆ
9	2025	11	สินค้ามีคุณภาพ	Positive	0	0	0	1	0	Store	คุณภาพ
10	2025	11	ลดราคาของหน่อยขอออ	Negative	0	0	1	1	1	Company, Store, Promotion	ส่วนลด

เพิ่มคอลัมน์ Topic การจัดกลุ่มหัวข้อรีวิว

- เพื่อรวมหัวข้อรีวิวที่กล่าวถึงสิ่งเดียวกัน เช่น ส่วนลด โปรโมชั่น หรือปัญหาการจัดส่ง
- สร้างตารางคำสำคัญ (Keyword Dictionary) สำหรับแต่ละหัวข้อย่อย
- ตรวจสอบข้อความรีวิวด้วยการจับคู่คำ (Keyword Matching)

  หากพบคำสำคัญ

  → กำหนด Topic ตามหัวข้อย่อยที่สอดคล้อง

  หากไม่พบคำใด

  → จัดเป็นหมวด “อื่นๆ”
- กำหนดให้ 1 รีวิวมี 1 Topic หลัก

จากนั้นจะนำไฟล์ข้อมูลเข้าสู่ Power bi เพื่อจัดทำแดชบอร์ด

	Sub_Topic	Keyword
2	ส่วนลด	ส่วนลด
3	ส่วนลด	ลดราคา
4	ส่วนลด	ลด
5	โปรโมชั่น	โปรโมชั่น
6	โปรโมชั่น	โปร
7	คูปอง	คูปอง
8	คูปอง	ส่งฟรี
9	เวลาการจัดส่ง	ช้า
10	เวลาการจัดส่ง	ล่าช้า
11	เวลาการจัดส่ง	ส่งช้า
12	เวลาการจัดส่ง	รอนาน
13	เวลาการจัดส่ง	ยังไม่ได้ของ
14	เวลาการจัดส่ง	ยังไม่ถึง
15	เวลาการจัดส่ง	เลื่อนส่ง
16	เวลาการจัดส่ง	ไม่อัปเดตสถานะ
17	เวลาการจัดส่ง	สถานะไม่อัปเดต
18	เวลาการจัดส่ง	ตรวจสอบสถานะ
19	เวลาการจัดส่ง	ส่งไว
20	เวลาการจัดส่ง	ตรงเวลา
21	เร็ว	รวดเร็ว
22	เวลาการจัดส่ง	วันเดียวถึง
23	ปัญหาพนักงานขนส่ง	พนักงานขนส่ง
24	ปัญหาพนักงานขนส่ง	พูดไม่สุภาพ
25	ปัญหาพนักงานขนส่ง	บริการแย่
26	ปัญหาพนักงานขนส่ง	ไม่โทร
27	ปัญหาพนักงานขนส่ง	ติดต่อไม่ได้

aspect_sentiment_final | Keywords

ตัวอย่าง

ค่าส่วนลด
ดีค่ะมีส่วนลดเยอะมาก
ส่วนลดเยอะมาก
มีส่วนลดค่าจัดส่งดี
มีส่วนลดมากมาย
ใช้ลดราคาได้ไม่จำกัด
ราคาดีรับส่วนลดเยอะ
ดีมากกแต่ต้องดูรีวิวก่อนสั่งเพราะมีบ้างร้านอาจไม่ตรงปกรวม
ดีมากๆคับลดราคาเยอะมาก
ส่วนลดดีมาก
มีคูปองส่วนลดค่าขนส่ง
อยากให้ใช้แต้มส่วนลดลดค่าส่งเพิ่มได้
มีส่วนลด
อยากให้มีส่วนลดเยอะๆ
ให้ส่วนลดดีพอสินค้าส่งไม่ตรงก็โอนเงินคืนให้ไวสินค้าดีทุกดี
ใช้ดีมากครับแถมโค้ดส่วนลดได้เยอะมาก

Dashboard การวิเคราะห์ความคิดเห็นของผู้ใช้แอปพลิเคชัน Lazada จาก Google Play Store

Lazada

สัดส่วนความคิดเห็นเชิงบวก

38.49%
Positive % (Overall)

สัดส่วนความคิดเห็นเชิงลบ

28.63%
Negative % (Overall)

สัดส่วนความคิดเห็นเป็นกลาง

32.88%
Neutral % (Overall)

Aspect

Select all | Company | Logistics | Promotion | Store | System

จำนวนความคิดเห็นเชิงบวก เชิงลบ และเป็นกลาง จำแนกตามประเด็น (Aspect-based Sentiment)

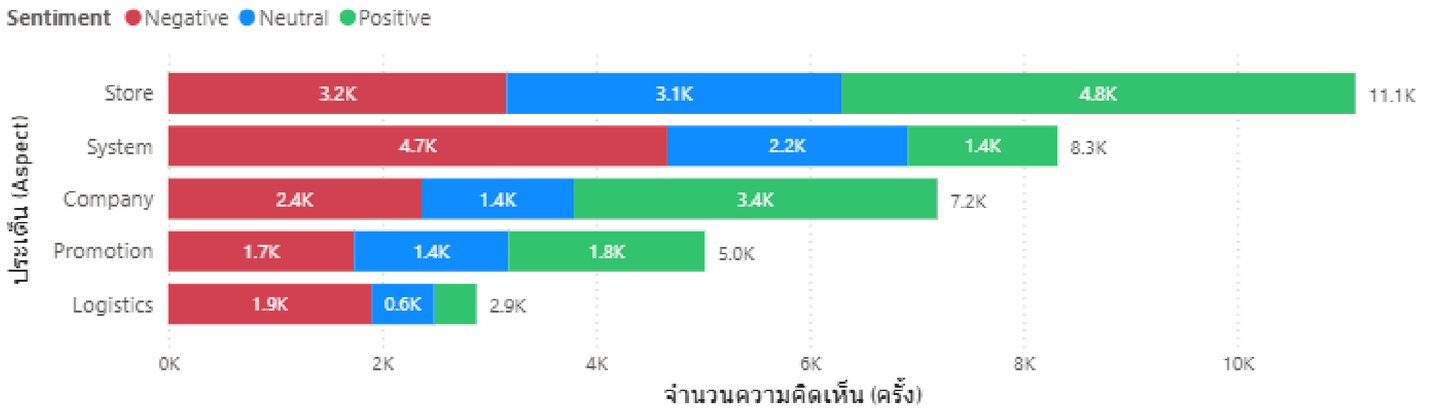

ตัวอย่างความคิดเห็นเชิงลบจริงจากผู้ใช้

เก็บโค้ดส่วนลดก็ไม่ได้แย่มาก

จำนวนความคิดเห็นจำแนกตามประเด็น

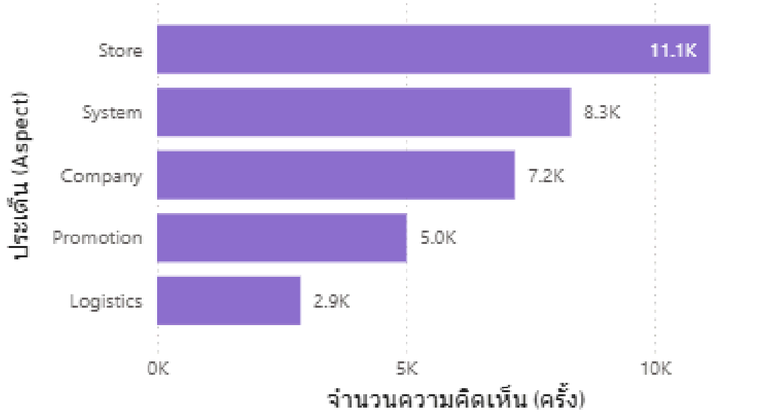

จำนวนความคิดเห็นเชิงลบจำแนกตามประเด็น

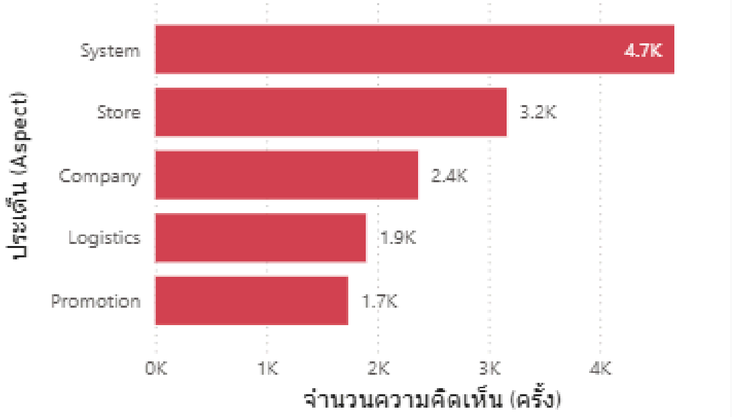

หัวข้อรีวิวที่ถูกกล่าวถึงมากที่สุด 3 อันดับแรกของแต่ละประเด็น

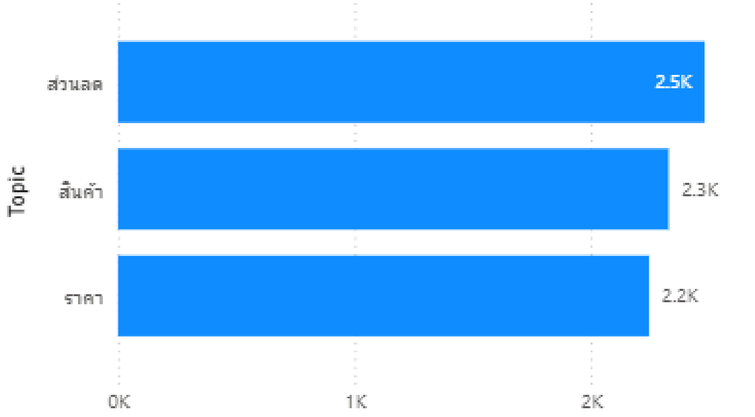

RMUTP

Thank You

SENTIMENT ANALYSIS OF USER REVIEWS FOR THE LAZADA APPLICATION ON GOOGLE PLAY STORE